

Universitat Rovira i Virgili
Escola Tècnica Superior d'Enginyeria

ESTADÍSTICA

PRÀCTICA 7

FASE 2

NOM: IVAN MORILLAS GOMEZ

3/12/2021

2021-2022

Plantejament inicial:

Iniciar la resolució d'aquest problema requereix d'operacions amb les dades lliurades, per tant, el primer que s'ha de fer és carregar-les per tal de poder començar a treballar. El desenvolupament de la pràctica ha estat realitzat amb el llenguatge de programació R.

Primer de tot, he creat un arxiu .txt amb les dades de la pràctica i després l'importaré dins del programa on les comes són el separador i els punts són els caràcters decimals.

```
> Dades <- read.table("/home/dades.txt", header=FALSE, sep=",", na.strings="NA", dec=".", strip.white=TRUE)
```

```
> Dades
      V1    V2
1  2.76  7.02
2  5.18  3.10
3  2.68  5.44
4  3.05  3.99
5  4.10  5.21
6  7.05 10.26
7  6.60 13.91
8  4.79 18.53
9  7.39  7.91
10 7.30  4.85
11 11.78 11.10
12 3.90  3.74
13 26.00 94.03
14 67.48 94.03
15 17.04 41.70
```

On V1 és el conjunt de dades al moment de la injecció i V2 és el conjunt de dades després de 30 minuts de la injecció

Ara, amb una comanda del llenguatge R, puc posar les dades horitzontalment per a una millor visualització i poder començar a treballar.

```
> V1 = as.numeric(as.character(Dades$V1))

> print(V1)
[1] 2.76 5.18 2.68 3.05 4.10 7.05 6.60 4.79 7.39 7.30 11.78 3.90 26.00 67.48 17.04

> V2 = as.numeric(as.character(Dades$V2))

> print(V2)
[1] 7.02 3.10 5.44 3.99 5.21 10.26 13.91 18.53 7.91 4.85 11.10 3.74 94.03 94.03 41.70
```

Doneu una estimació puntual del valor en mitjana i de la desviació poblacional de la variable X_M :

La primera tasca demanada és el calcul de l'estimació puntual del valor en mitjana i de la desviació poblacional del conjunt de dades V1.

Per a calcular la estimació puntual de la mitjana, sencillament amb la comanda 'mean' ens calcula la mitjana.

```
> mitjanaV1 = mean(V1)
> cat("L'estimació puntual de la mitjana de V1 és de: ", mitjanaV1, "\n")
L'estimació puntual de la mitjana de V1 és de: 11.80667
```

Per a calcular la estimació puntual de la desviació poblacional, sencillament amb la comanda 'sd' ens calcula la desviació poblacional.

```
> desviacioV1 = sd(V1)
> cat("L'estimació puntual de la desviació poblacional de V1 és de: ", desviacioV1, "\n")
L'estimació puntual de la desviació poblacional de V1 és de: 16.63641
```

Calculeu un interval de confiança al 99% per al valor de la diferència de concentracions:

Per calcular intervals de confiança, R facilita funcions que desenvolupen automàticament els càlculs per arribar a diferents resultats sobre l'estudi de mostres, en concret, un dels resultats és l'interval de confiança.

Per a començar, restem els valors dels dos conjunts de concentracions i ens quedaria un conjunt així:

```
> Vresta = (V1-V2)
> print(Vresta)
[1] -4.26 2.08 -2.76 -0.94 -1.11 -3.21 -7.31 -13.74 -0.52 2.45 0.68 0.16 -68.03 -26.55 -24.66
```

I ara, per tal d'estudiar aquest conjunt, s'utilitzarà la funció de R 't.test()', una prova t-Student. Agafarem el conjunt de dades i un nivell de confiança del 99%=0.99 (el demanat) i ens surt això:

```
> t.test(Vresta, conf.level = 0.99)
```

```
One Sample t-test
```

```
data: Vresta
t = -2.0646, df = 14, p-value = 0.058
alternative hypothesis: true mean is not equal to 0
99 percent confidence interval:
 -24.047153  4.351153
sample estimates:
mean of x
 -9.848
```

A la cinquena línia dels resultats es mostren dos números decimals separats per un espai, aquest és l'interval que buscavem:

{-24.047153 , 4.351153}

Amb un risc de 0.05, pot assegurar-se que les concentracions d'andrògens augmenten després de 30 minuts d'inhibició?:

Per comprovar si les concentracions d'andrògens augmenten, faré dos tests d'hipotesis, un per a cada conjunt de dades amb la comanda t.test() amb un nivell de confiança del 95%=0.95

```
One Sample t-test
```

```
data: V1
t = 2.7486, df = 14, p-value = 0.01569
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 2.593728 21.019605
sample estimates:
mean of x
 11.80667
```

```
One Sample t-test
```

```
data: V2
t = 2.7124, df = 14, p-value = 0.01684
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 4.531354 38.777980
sample estimates:
mean of x
 21.65467
```

Com es pot veure, si comparem les dos mitjanes obtingudes amb les hipòtesis, la diferencia de mitjanes entre el conjunt de dades de V2, o sigui, després de 30 minuts d'inhibició i el conjunt de dades de V1, o sigui, al moment de la injecció, és d'aproximadament 10. Llavors podem concloure que es pot assegurar que les concentracions augmenten després de 30 minuts d'inhibició.

Podíem fer la suposició que la distribució dels dos conjunts de dades és normal? I que el primer conjunt té distribució exponencial?:

La següent demostració que es demana es per la confirmació de normalitat en les dades. Com no es tenen gaires dades ($n < 30$) s'aplicarà el test de Kolmogorov-Smirnov per verificar si les dades es poden considerar distribucions normals. En aquest test s'haurà d'avaluar el resultat de l'estadístic de prova i comparar-lo amb el corresponent valor de la taula KSL, en cas que es compleixi $EP < \text{valorTaula}$ s'acceptarà la hipòtesis nul·la H_0 , per tant, es podrà considerar normalitat en les dades. En cas contrari, no es pot confirmar normalitat. El nivell de significació que es seguirà per al test serà de 0.05. La hipòtesis serà bilateral, ja que es vol comprovar si es pot considerar o no una distribució.

```
> ks.test(V1, pnorm, mitjanaV1, desviacioV1)
```

```
One-sample Kolmogorov-Smirnov test
```

```
data: V1  
D = 0.33801, p-value = 0.04955  
alternative hypothesis: two-sided
```

```
> ks.test(V2, pnorm, mitjanaV2, desviacioV2)
```

```
One-sample Kolmogorov-Smirnov test
```

```
data: V2  
D = 0.34025, p-value = 0.06204  
alternative hypothesis: two-sided
```

En ambdues mostres no es poden considerar una distribució normal en les dades, ja que els valors de la D, que és l'estadístic de prova, són superiors, en ambdós casos, al valor de les taules (per a $\alpha=0.05$).

```
> ks.test(V1, pexp, mitjanaV1, desviacioV1)
```

```
One-sample Kolmogorov-Smirnov test
```

```
data: V1  
D = 1, p-value < 2.2e-16  
alternative hypothesis: two-sided
```

```
> ks.test(V2, pexp, mitjanaV2, desviacioV2)
```

```
One-sample Kolmogorov-Smirnov test
```

```
data: V2  
D = 1, p-value = 1.872e-13  
alternative hypothesis: two-sided
```

Oblidant ara tots els resultats obtinguts anteriorment, hi ha evidències significatives que els dos conjunts de dades tenen una diferència de mitjanes de, com a mínim, 3 nanograms?:

En el següent apartat ens demana cercar si existeix evidència suficient per considerar que hi ha diferència de com a mínim 3 nanograms entre els dos conjunts de dades.

Es planteja com a hipòtesis nul·la $H_0: \mu_0 \geq 3$ i com a hipòtesis alternativa $H_1: \mu_0 < 3$.

```
> t.test(V1, V2, "less", mu = 3, conf.level = 0.99)
```

```
Welch Two Sample t-test
```

```
data: V1 and V2  
t = -1.4172, df = 21.479, p-value = 0.08539  
alternative hypothesis: true difference in means is less than 3  
99 percent confidence interval:  
-Inf 12.93524  
sample estimates:  
mean of x mean of y  
11.80667 21.65467
```

Per a aquest cas, es compleix la hipòtesis nul·la, la diferència entre les mitjanes tenen una diferència de com a mínim 3 nanograms.

Mitjançant un procés d'anàlisi de la variància, contrasteu si hi ha diferència significativa entre les mitjanes de les tres mostres:

Per tal de generar les dades necessàries amb una distribució normal es farà ús de la funció de R 'rnorm()'.

```
> V3 = rnorm(15, mean(mitjanaV1, mitjanaV2), mean(desviacioV1, desviacioV2))  
  
> print(V3)  
[1] 28.848212 -4.179103 10.459258 -15.480646 8.840779 26.391388 9.809877 28.895268 -3.138826 44.230319  
[11] -14.636376 4.484494 21.350797 -10.360441 6.295155
```

Posteriorment, s'han d'unir les dades donades amb les noves generades i, per preparar les dades per a l'ús de la funció de test ANOVA, es juntaran les dades en un mateix vector.

```
> V4 = c(V1, V2, V3)  
  
> print(V4)  
[1] 2.760000 5.180000 2.680000 3.050000 4.100000 7.050000 6.600000 4.790000 7.390000 7.300000 11.780000  
[12] 3.900000 26.000000 67.480000 17.040000 7.020000 3.100000 5.440000 3.990000 5.210000 10.260000 13.910000  
[23] 18.530000 7.910000 4.850000 11.100000 3.740000 94.030000 94.030000 41.700000 28.848212 -4.179103 10.459258  
[34] -15.480646 8.840779 26.391388 9.809877 28.895268 -3.138826 44.230319 -14.636376 4.484494 21.350797 -10.360441  
[45] 6.295155
```

Per discernir entre les classificacions de les dades del vector V4, es crearan vectors que classifiquin la informació. Aquest vector classificadors s'apliquen amb la funció 'factor()'.

```
> tipus = rep(1:3, each = 15)  
  
> tipus = factor(tipus, labels = c("Al moment", "30 minuts", "Noves dades"))
```

L'últim pas que queda és fer el test ANOVA, en R la funció 'aov()' realitzarà aquesta feina.

```
> p.aov = aov(V4 ~ tipus)  
  
> model.tables(p.aov)  
Tables of effects  
  
tipus  
tipus  
Al moment 30 minuts Noves dades  
-2.498 7.350 -4.851  
  
> model.tables(p.aov, type = "mean")  
Tables of means  
Grand mean  
  
14.30511  
  
tipus  
tipus  
Al moment 30 minuts Noves dades  
11.807 21.655 9.454
```

Segons les dades resultants, com que el p-valor es molt petit, es pot concloure que les diferències de les mitjanes entre els tres conjunts és significatiu.